

---

QUIZZ : Modèle linéaire

---

## 1 Général :

- 1) Que vaut  $Cov(X + \mu)$  pour tout  $\mu \in \mathbb{R}^p$  déterministe, et tout vecteur aléatoire  $X \in \mathbb{R}^p$  ?
- 2) Que vaut  $Cov(AX)$ , pour toute matrice  $A \in \mathbb{R}^{m \times p}$  et tout vecteur aléatoire  $X \in \mathbb{R}^p$  ?
- 3) Donner un modèle naturel pour "un lancer de dé" (non-nécessairement équilibré) ?
- 4) Soit  $x_1, x_2, \dots, x_n$  i.i.d. tel que  $\mathbb{E}[x_1^2] < \infty$ . Quel estimateur  $\hat{\mu}$  minimise  $\sum_{i=1}^n (x_i - \mu)^2$  ? Donner son biais et sa variance, pour tout  $n > 1$ .
- 5) Que vaut le biais de  $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_n)^2$  ( $\bar{y}_n$  est la moyenne empirique) pour des  $y_i$  i.i.d, gaussiens, centrés et de variance  $\sigma^2$  ?
- 6) On suppose que l'on observe  $y_1, \dots, y_n$ , des variables réelles i.i.d., gaussiennes, centrées et de variance  $\sigma^2$ . Quel est le risque quadratique de l'estimateur  $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_n)^2$  de  $\sigma^2$  ( $\bar{y}_n$  est la moyenne empirique) ?
- 7) Quelle est la projection orthogonal du vecteur  $\mathbf{y} \in \mathbb{R}^n$  sur  $\text{Vect}(1_n)$ , avec  $1_n = (1, \dots, 1)^\top \in \mathbb{R}^n$  ?
- 8) Quels sont les vecteurs  $\mathbf{y} \in \mathbb{R}^n$  tels que  $\text{var}_n(\mathbf{y}) = 0$  ( $\text{var}_n$  est la variance empirique) ?

## 2 Moindres carrés unidimensionnels :

On observe  $\mathbf{y} = (y_1, \dots, y_n)^\top$  et  $\mathbf{x} = (x_1, \dots, x_n)^\top$

- 1) La fonction  $(\theta_0, \theta_1) \rightarrow \frac{1}{2} \sum_{i=1}^n (y_i - \theta_0 - \theta_1 x_i)^2$  est elle convexe ou concave ?
- 2) Donner la formule  $(\hat{\theta}_0, \hat{\theta}_1)$  des estimateurs des moindres carrés où  $\hat{\theta}_0$  correspond au coefficient des constantes et  $\hat{\theta}_1$  correspond à l'influence de  $\mathbf{x}$  sur  $\mathbf{y}$ . On les exprimera en fonction des  $x_i, y_i, \bar{x}_n, \bar{y}_n$

## 3 Moindres carrés :

On note ici  $\mathbf{y} = (y_1, \dots, y_n)^\top \in \mathbb{R}^n$  et  $X \in \mathbb{R}^{n \times p}$  (sauf mention contraire).

- 1) Écrire un pseudo-code de descente de gradient pour résoudre le problème des moindres carrés.
- 2) Pour une matrice  $X \in \mathbb{R}^{n \times p}$ , que vaut  $\text{Ker}(X^\top X)$  ?
- 3) Pour une matrice  $X \in \mathbb{R}^{n \times (p+1)}$ ,  $n > 1$  et  $p \geq 1$ , qui possède comme première colonne une colonne de 1, notons  $(1, \tilde{X}_i^\top) \in \mathbb{R}^{p+1}$ , les lignes de  $X$ . Montrer que  $X^\top X$  non-inversible est équivalent à

$$\sum_{i=1}^n (\tilde{X}_i - \hat{\mu}_n)(\tilde{X}_i - \hat{\mu}_n)^\top \text{ non-inversible,}$$

où  $\hat{\mu}_n = \sum_{i=1}^n \tilde{X}_i$ .

- 4) Si la matrice  $X \in \mathbb{R}^{n \times p}$  est de plein rang, donner une formule exacte de l'estimateur des moindres carrés.
- 5) Si la matrice  $X \in \mathbb{R}^{n \times p}$  n'est pas de plein rang, donner une formule pour un estimateur des moindres carrés.
- 6) Décrire les 2 cas possibles quant à la définition de l'estimateur des moindres carrés (existence et unicité).
- 7) Quand l'estimateur des moindres carrés est non-unique, quel est l'ensemble des solutions du problème d'optimisation associé ?
- 8) Si la matrice  $X \in \mathbb{R}^{n \times p}$  est de plein rang, donner la matrice de covariance de l'estimateur des moindres carrés (dans l'hypothèse d'un bruit  $\varepsilon = \mathbf{y} - X\theta^*$  centré et de matrice de covariance  $\sigma^2 \text{Id}_n$ ).
- 9) Donner un estimateur sans biais du niveau du bruit  $\sigma^2$  (dans le cas où le  $X$  est déterministe).
- 10) On suppose que  $X$  est de rang plein et on note  $\hat{\theta}_n$  l'estimateur OLS. On note  $\tilde{X} = (\tilde{X}_1, \dots, \tilde{X}_p)$ . On change l'échelle d'une des variables :  $\tilde{X}_k$  est remplacé par  $\tilde{X}_k b$ , où  $b > 0$ .
  - (a) Soit  $X_b = (1, X_1, \dots, X_k b, \dots, X_p)$ . Montrer que  $X_b = XD$  où  $D$  est une matrice diagonale que l'on précisera.
  - (b) Soit  $\hat{\theta}_{b,n}$  l'estimateur OLS associé à  $X_b$ . Exprimer  $\hat{\theta}_{b,n}$  en fonction de  $\hat{\theta}_n$  et  $D$ .
  - (c) Donner la variance de  $\hat{\theta}_{b,n}$ .
  - (d) On a vu que l'estimateur  $\hat{\theta}_n$  était affecté par un changement d'échelle. Qu'en est-il de la valeur prédite par le modèle ?
- 11) Donner une formule explicite du problème  $\arg \min_{\theta} \frac{1}{2}(\mathbf{y} - X\theta)^\top \Omega (\mathbf{y} - X\theta)$  pour une matrice  $\Omega = \text{diag}(w_1, \dots, w_n)$  définie positive, dans le cas où  $X$  est de plein rang.
- 12) Dans le cas du modèle de régression avec design aléatoire, décrire l'asymptotique de l'estimateur des moindres carrés. On donnera la loi asymptotique de  $\sqrt{n}(\hat{\beta} - \beta^*)$ .
- 13) Dans le cas du modèle de régression avec design déterministe et bruit gaussien centré de variance  $\sigma^2$ , donner la loi de l'estimateur des moindres carrés  $\hat{\beta}$ .
- 14) Dans le cas du modèle de régression avec design déterministe où  $X$  est de plein rang  $p$ , donner la valeur du risque de prédiction.

## 4 Ridge :

On note  $\hat{\theta} = \arg \min_{\theta} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \frac{\lambda}{2} \|\theta\|_2^2$  l'estimateur Ridge

- 1) Donner une formule explicite pour l'estimateur Ridge en fonction de  $y$  et  $\lambda$  quand  $X = \text{Id}_n$ .
- 2) Donner une formule explicite pour l'estimateur Ridge en fonction de  $X$ ,  $y$  et  $\lambda$ .
- 3) Donner la variance de l'estimateur Ridge sous l'hypothèse que le bruit  $\mathbf{y} - X\theta^*$  est centré et de variance  $\sigma^2 \text{Id}_n$ .
- 4) Donner en fonction de  $X$ ,  $y$ ,  $D \in \mathbb{R}^{p \times p}$  et  $\lambda$ , une formule explicite de

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \frac{\lambda}{2} \|D\theta\|_2^2,$$

## 5 Lasso :

- 1) Exprimer  $\eta_\lambda(z) = \arg \min_{x \in \mathbb{R}} x \mapsto \frac{1}{2}(z - x)^2 + \lambda|x|$  en fonction du signe de  $x$  et de la partie positive  $(\cdot)_+$ .

- 2) Donner en tout point la sous-différentielle de la fonction réelle  $x \mapsto (x)_+ = \max(x, 0)$ .
- 3) Donner l'étape de mise à jour principale en descente par coordonnée pour résoudre le problème de l'*Elastic Net* :  $\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}^p} \left[ \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \lambda \left( \alpha \|\theta\|_1 + (1 - \alpha) \frac{\|\theta\|_2^2}{2} \right) \right]$ .
- 4) Donner l'étape de mise à jour principale en descente par coordonnée pour résoudre le problème du *Lasso Positif* :  $\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}_+^p} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \lambda \|\theta\|_1$ .
- 5) Donner l'étape de mise à jour principale en descente par coordonnée pour résoudre le problème :

$$\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}^p, s.c. \Omega \theta \geq 0} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2,$$

avec  $\Omega = \text{diag}(w_1, \dots, w_n)$ .

- 6) On suppose que l'on dispose d'un solveur Lasso( $X, y, \lambda$ ) qui résout le problème du Lasso  $\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}^p} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \lambda \|\theta\|_1$ . En utilisant ce solveur, comment résoudre le problème suivant :  $\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}^p} \frac{1}{2} \|\mathbf{y} - X\theta\|_2^2 + \lambda \sum_{j=1}^p w_j |\theta_j|$ , pour des  $w_j \geq 0$  ?

## 6 ACP/SVD :

- 1) Donner la formulation de la pseudo inverse de  $X$  connaissant sa SVD :  $X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^\top$ , avec  $r = \text{rg}(X)$  et  $s_1 \geq \dots \geq s_r > 0$ .
- 2) Que vaut  $\begin{cases} \max_{u \in \mathbb{R}^n, v \in \mathbb{R}^p} u^\top X v \\ \text{s.c. } \|u\|_2^2 = 1 \text{ et } \|v\|_2^2 = 1 \end{cases}$  ?

## 7 Test :

- 1) Pour des  $X_1, \dots, X_n$  identiquement distribuées à valeur dans  $\{0, 1\}$ , décrire une procédure de test de l'hypothèse  $p = P(X_1 = 1) = 1/2$  contre son contraire.
- 2) Soient  $X_1, \dots, X_n$  des variables aléatoires i.i.d selon des lois gaussiennes de moyenne (inconnue)  $\mu$  et de variance connue  $\sigma^2$ , i.e.,  $X_i \sim \mathcal{N}(\mu, \sigma^2)$ . Décrire une procédure de test de l'hypothèse  $\mu = 1$  contre son contraire.
- 3) Soient  $X_1, \dots, X_n$  des variables aléatoires indépendantes et distribuées selon des lois gaussiennes de moyenne (inconnue)  $\mu$  et de variances connues  $\sigma_i^2$ , i.e.,  $X_i \sim \mathcal{N}(\mu, \sigma_i^2)$ . Décrire une procédure de test de l'hypothèse  $\mu = 1$  contre son contraire.

## 8 Bootstrap :

- 1) Soient  $\epsilon_1, \dots, \epsilon_n$  des variables aléatoires i.i.d. de loi gaussienne de moyenne (inconnue)  $\mu$  et de variance (connue)  $\sigma^2$ , i.e.,  $\epsilon_i \stackrel{i.i.d}{\sim} \mathcal{N}(\mu, \sigma^2)$ . On observe  $(y_i, x_i)_{i=1, \dots, n}$  tel que, pour chaque  $i = 1, \dots, n$ ,  $y_i = x_i^T \beta + \epsilon_i$  et  $x_i$  déterministe.
  - (a) La variable  $y_1$  est-elle indépendante de  $y_2$  ? La variable  $y_1$  a-t-elle même loi que  $y_2$  ? Donner la distribution de  $y_i$ .
  - (b) Soit  $\hat{\beta}$  l'estimateur OLS du modèle  $y_i = x_i^T \beta + \epsilon_i$ . A l'aide de résidus bootstrap  $(\epsilon_i^*)_{i=1, \dots, n} \stackrel{i.i.d}{\sim} \mathcal{N}(\mu, \sigma^2)$ , calculer  $(y_i^*)_{i=1, \dots, n}$  et donner leur loi. Calculer l'estimateur bootstrap  $\hat{\beta}^*$  et donner la loi de  $\sqrt{n}(\hat{\beta}^* - \hat{\beta})$ .
- 2) Proposer une procédure bootstrap sur les résidus pour estimer l'écart quadratique moyen de la méthode des moindres carrés dans le cas d'une régression linéaire.