

Optimisation

3 séries d'optimisation

• exemple de problèmes d'optimisation :

soit une fonction $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

On cherche $x \in \mathbb{R}^n$ tel que $\forall y \in \mathbb{R}^n, f(x) \leq f(y)$

C'est le problème : $\min_{x \in \mathbb{R}^n} f(x)$

• autre exemple : les moindres carrés (quadratique convexe)

• Définition :

une fonction f est convexe si :

$$\forall x \in \mathbb{R}^n, \forall y \in \mathbb{R}^n, \forall t \in [0, 1] :$$

$$f(t x + (1-t) y) \leq t f(x) + (1-t) f(y)$$



Proposition :

Si f est convexe et dérivable, alors $\forall y \in \mathbb{R}^p, \forall x \in \mathbb{R}^p$,
 $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$

démonstration:

soit $x \in \mathbb{R}^p$ et $y \in \mathbb{R}^p$, et soit $t \in [0, 1]$.

$$f(x + t(y - x)) = f(x) + t \langle \nabla f(x), y - x \rangle + o(t) \quad \text{car dérivable}$$

où $o(t)$ vérifie $\lim_{t \rightarrow 0} \frac{o(t)}{t} = 0$

$$f(x + t(y - x)) = \lim_{t \rightarrow 0} f(t y + (1-t)x) \leq t f(y) + (1-t) f(x) \quad \text{convexité}$$

donc: $t f(y) + (1-t) f(x) \geq f(x) + t \langle \nabla f(x), y - x \rangle + o(t)$

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{o(t)}{t} \quad (\text{soustrait } f(x), \text{ divise par } t)$$

Je fais tendre t vers 0:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$$

Théorème:

Si f est dérivable et x^* est un minimiseur de f ,
alors $\nabla f(x^*) = 0$

démonstration:

$$\forall y \in \mathbb{R}^p, f(y) \geq f(x^*) \quad (\text{car } x^* \text{ minimiseur})$$

$$f(x^* + t(y - x^*)) = f(x^*) + t \langle \nabla f(x^*), y - x^* \rangle + o(t), \quad t \in \mathbb{R}$$

$$f(x^*) + t \langle \nabla f(x^*), y - x^* \rangle + o(t) \geq f(x^*)$$

$$\langle \nabla f(x^*), y - x^* \rangle + \frac{o(t)}{t} \geq 0 \quad (\text{soustrait } f(x^*), \text{ divise par } t)$$

Je fais tendre vers 0: j'obtiens que $\forall y \in \mathbb{R}^p$,

$$\langle \nabla f(x^*), y - x^* \rangle \geq 0$$

$$\text{Je choisis } y = x^* - \nabla f(x^*):$$

$$- \|\nabla f(x^*)\|^2 \geq 0$$

$$\text{et donc } \nabla f(x^*) = 0$$

Théorème:

si f est convexe et dérivable, alors:

$$x^* \text{ minimiseur de } f \Leftrightarrow \nabla f(x^*) = 0$$

(autrement dit, il suffit de trouver un point tel
que $\nabla f(x) = 0$ pour avoir un minimum).

Démonstration:

• si x^* est minimiseur, alors $\nabla f(x^*) = 0$ (par ce qui précède).

• si f est convexe:

$$\forall y \in \mathbb{R}^p, f(y) \geq f(x^*) + \underbrace{\langle \nabla f(x^*), y - x^* \rangle}_{=0} \geq f(x^*)$$

donc x^* minimiseur de f .

Revenons aux moindres carrés:

$$f(\beta) = \frac{1}{2} \|X\beta - y\|_2^2$$

$$\nabla f(\beta) = X^T(X\beta - y)$$

$$\beta^* \in \underset{\mathbb{R}^p}{\operatorname{argmin}} f(\beta) \Leftrightarrow \nabla f(\beta^*) = 0 \Leftrightarrow X^T X \beta^* = X^T y$$

Analyse en composante principale:

$$\min_{M \in \mathbb{R}^{p \times n}} \|A - M^T M\|^2, \quad A \in \mathbb{R}^{n \times n}$$

Lasso:

$$\min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - y\|_2^2 + \lambda \|\beta\|_1$$

résolu avec l'opérateur proximal:

$$\operatorname{prox}_{\lambda, 1}(\beta) = \underset{b \in \mathbb{R}}{\operatorname{argmin}} |b| + \frac{1}{2} (\beta - b)^2 \quad (\text{seuilage doux})$$

NMF:

$$A \in \mathbb{R}^{n \times p}$$

$$\min_{U \in \mathbb{R}^{n \times q}, V \in \mathbb{R}^{q \times p}} \|A - UV\|_F^2 \quad U_{ij} \geq 0 \quad \forall i, j \quad V_{j\ell} \geq 0 \quad \forall j, \ell$$

non convexe avec contraintes

Régression logistique:

$$\text{modèle linéaire: } y_i = x_i^T w + w_0 + \varepsilon_i$$

$$\text{classification: } y_i \in \{-1, 1\}$$

$$\text{classifieur: } h = x \mapsto \operatorname{sign}(\langle x, w \rangle + w_0) \quad (w \in \mathbb{R}^p, w_0 \in \mathbb{R})$$

→

problème d'optimisation :

$$\min_{w \in \mathbb{R}^p, w_0 \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \log(1 + \exp)$$

fonctions composées :

$$f: \mathbb{R}^p \rightarrow \mathbb{R}^q$$

$$g: \mathbb{R}^q \rightarrow \mathbb{R}^m$$

$$g \circ f: \mathbb{R}^p \rightarrow \mathbb{R}^m$$

$$x \mapsto g(f(x))$$

$$\text{Jacobiens : } J_{g \circ f}(x) = J_g(f(x)) \times J_f(x)$$

Réseau de neurones :

$$L(y, \hat{y}) = \sum_{i=1}^n \|y_i - \hat{y}_i\|^2$$

$$\sigma: \mathbb{R} \rightarrow \mathbb{R}$$

$$N: \mathbb{R}^H \times \mathbb{R}^H \rightarrow \mathbb{R}$$

$$(w, v) \mapsto \sum_{i=1}^H w_i v_i$$

$$v_i: \mathbb{R}^H \rightarrow \mathbb{R}^H$$

$$z \mapsto \begin{pmatrix} v_1(z_1) \\ \vdots \\ v_H(z_H) \end{pmatrix}$$

$$X: W \mapsto \left(\sum_{j=1}^p W_{ij} x_j \right)_{1 \leq i \leq H}$$

$$F(w, W) = L(y, \sigma(N(w, v(X(N))))))$$