

# Exemples de problèmes d'optimisation en apprentissage automatique

Quadratique convexe

Dérivable convexe

Convexe non-dérivable

Convexe avec contraintes

Non-convexe dérivable

Non-convexe non dérivable

Combinatoire

# Moindres carrés

Modèle linéaire :  $y_i = x_i^\top \beta + \varepsilon_i$

$x_i$  : variables explicatives pour l'observation  $i$

$\beta$  : vecteur des paramètres du modèle

$\varepsilon_i$  : bruit

Problème d'optimisation

$$\min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - y\|_2^2 = \min_{\beta \in \mathbb{R}^p} \frac{1}{2} \sum_{i=1}^n (x_i^\top \beta - y_i)^2$$

$$X \in \mathbb{R}^{n \times p}, y \in \mathbb{R}^n$$

[Retour accueil](#)

# Régularisation de Tikhonov (ridge regression)

Modèle linéaire :  $y_i = x_i^\top \beta + \varepsilon_i$

On veut forcer  $\beta$  à ne pas avoir des coefficients immenses

Problème d'optimisation

$$\min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - y\|_2^2 + \frac{\lambda}{2} \|\beta\|_2^2$$

$$X \in \mathbb{R}^{n \times p}, y \in \mathbb{R}^n, \lambda > 0$$

[Retour accueil](#)

# Régression logistique

Modèle linéaire :  $y_i = x_i^\top w + w_0 + \varepsilon_i$

Classification :  $y_i \in \{-1, 1\}$

Classifieur :

$$h : x \mapsto \text{sign}(\langle x, w \rangle + w_0) \quad (w \in \mathbb{R}^p, w_0 \in \mathbb{R})$$

Problème d'optimisation

$$\min_{w \in \mathbb{R}^p, w_0 \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \log(1 + \exp(-y_i(x_i^\top w + w_0))) + \frac{\lambda}{2} \|w\|^2$$

[Retour accueil](#)

# Lasso

Modèle linéaire :  $y_i = x_i^\top \beta + \varepsilon_i$

On veut un vecteur de paramètre  $\beta$  parcimonieux  
(beaucoup de coefficients égaux à 0)

Problème d'optimisation

$$\min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - y\|_2^2 + \lambda \|\beta\|_1$$

$X \in \mathbb{R}^{n \times p}, y \in \mathbb{R}^n, \lambda > 0$

$\|\beta\|_1 = \sum_{i=1}^p |\beta_i|$  pas dérivable mais séparable

[Retour accueil](#)

# Séparateurs à Vaste Marge (SVM)

Modèle linéaire :  $y_i = x_i^\top w + w_0 + \varepsilon_i$

Classification :  $y_i \in \{-1, 1\}$

Classifieur :

$h : x \mapsto \text{sign}(\langle x, w \rangle + w_0) \quad (w \in \mathbb{R}^p, w_0 \in \mathbb{R})$

Problème d'optimisation

$$\min_{w \in \mathbb{R}^p, w_0 \in \mathbb{R}} \sum_{i=1}^n C \max(0, 1 - y_i(x_i^\top w + w_0)) + \frac{1}{2} \|w\|^2$$

[Retour accueil](#)

# SVM dual

Modèle linéaire :  $y_i = x_i^\top w + w_0 + \varepsilon_i$

Classification :  $y_i \in \{-1, 1\}$

Problème d'optimisation

$$\min_{\alpha \in \mathbb{R}^n} \sum_{j=1}^p \left( \sum_{i=1}^n \alpha_i y_i X_{i,j} \right)^2 - \sum_{i=1}^n \alpha_i$$
$$0 \leq \alpha_i \leq C, \forall i, \quad \sum_{i=1}^n y_i \alpha_i = 0$$

$$w_j = \sum_{i=1}^n \alpha_i y_i X_{i,j}$$

[Retour accueil](#)

# Réseaux de neurones

Modèle non-linéaire :  $y_i = f(x_i, w) + \varepsilon_i$

Exemple : 1 couche cachée avec  $H$  neurones

$$f(x, w) = \sigma \left( \sum_{i=1}^H w_i v_i \left( \sum_{j=1}^p w_{i,j} x_j \right) \right)$$

$\sigma, v_1, \dots, v_H$  sont appelées fonctions d'activation

Problème d'optimisation

$$\min_{w \in \mathbb{R}^{H+Hp}} \sum_{i=1}^n \|y_i - f(x_i, w)\|^2$$

[Retour accueil](#)



# ACP et NMF

A matrice de taille  $n \times p$

ACP :

$$\min_{U \in \mathbb{R}^{n \times k}, V \in \mathbb{R}^{k \times p}} \|A - UV\|_F^2$$

NMF :

$$\min_{U \in \mathbb{R}^{n \times k}, V \in \mathbb{R}^{k \times p}} \|A - UV\|_F^2$$
$$U_{i,j} \geq 0, V_{j,l} \geq 0$$

[Retour accueil](#)

# 0-1 Loss

Modèle linéaire :  $y_i = x_i^\top w + w_0 + \varepsilon_i$

Classification :  $y_i \in \{-1, 1\}$

Classifieur :

$$h : x \mapsto \text{sign}(\langle x, w \rangle + w_0) \quad (w \in \mathbb{R}^p, w_0 \in \mathbb{R})$$

Problème d'optimisation

$$\min_{w \in \mathbb{R}^p, w_0 \in \mathbb{R}} \sum_{i=1}^n \mathbb{1}(y_i(x_i^\top w + w_0) < 0)$$

[Retour accueil](#)

# $K$ plus proches voisins

$x_0$  fixé, on cherche les  $K$  plus proches voisins de  $x_0$

$$\begin{aligned} \min_{s \in \mathbb{Z}^n} \quad & \sum_{i=1}^n s_i \|x_0 - x_i\| \\ & 0 \leq s_i \leq 1, \forall i \\ & \sum_{i=1}^n s_i = K \end{aligned}$$

[Retour accueil](#)

# K-means

On cherche à partitionner les points  $(x_j)_{1 \leq j \leq n}$  en  $K$  ensembles  $S_1, \dots, S_K$

$$\min_{S_1, \dots, S_K} \sum_{k=1}^K \sum_{x_j \in S_i} \|x_j - \mu_k\|^2$$

$$\mu_k = \frac{1}{|S_k|} \sum_{x_j \in S_i} x_j, \forall k$$

$$S_j \cap S_i = \emptyset, \forall i, j$$

$$S_1 \cup \dots \cup S_K = \{1, \dots, n\}$$

[Retour accueil](#)