INF344 – Données du Web
Le langage HTML

Antoine Amarilli

Présentation générale

- HyperText Markup Language
- Décrit une page Web (il n'y a pas que ça sur le Web…)
- Normalisé par le W3C (industriels et académiques) et WHATWG
- Format ouvert documenté : HTML5 specification (548 pages, 2014)
- Langage à balises, structure et contenu du document
- Pas (ou peu) de présentation (CSS)
- Pas de comportements dynamiques (JavaScript)

SONDAGE : HTML et XML

Est-ce qu'une page Web HTML est un document XML ?

- **A**: Oui évidemment
- **B**: Normalement oui, sauf quand elle n'est pas valide
- **C**: Non, ça n'a aucun rapport
- **D**: C'est plus compliqué que ça

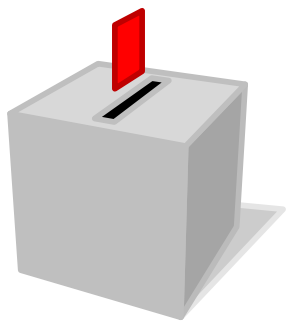

SONDAGE : HTML et XML

Est-ce qu'une page Web HTML est un document XML ?

- **A**: Oui évidemment
- **B**: Normalement oui, sauf quand elle n'est pas valide
- **C**: Non, ça n'a aucun rapport
- **D**: **C'est plus compliqué que ça**

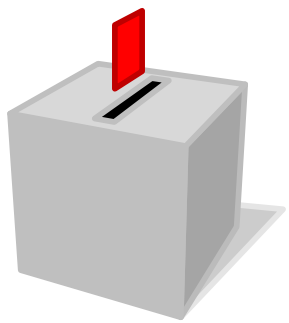

Versions

- Tentative complexe de langage général : SGML
- HTML inspiré de SGML, versions 1 à 4
- Tentative plus simple de langage général : XML
- XHTML : HTML conforme à XML (1.0 et 1.1)
- HTML 5 : pas du XML, mais... XHTML 5
- Maintenant un standard vivant (WHATWG)
- Autres formats dérivés de XML

→ Contrairement à HTTP : plusieurs versions dans la nature, et peu de respect pour les standards !

Table des matières

Principes du balisage

- Balise ouvrante (`<em>`) et fermante (`</em>`) :

  ```
  Exemple <em>illustratif</em>
  ```

- La nature et répétition des espaces est ignorée :

  ```
  Peu
      importe !
  ```

- Balises sans fermeture : `<br>` pour un retour à la ligne.
  (Ou `<br/>` par compatibilité avec XML.)
- Attributs :

  ```
  <p>Un <a href="https://example.com/">lien</a>.</p>
  ```

- Commentaires :

  ```
  <!-- non affiché -->
  ```

- Entités HTML : caractères rares et échappement

  ```
  <p>&lt;p&gt;C'est m&eacute;ta !&lt;/p&gt;</p>
  ```

Imbrication

- Il faut ouvrir et fermer les balises dans le **bon ordre** :
  `<a><b></b></a>` et non `<a><b></a></b>`
- **Règles** : interdit de mettre n'importe quelle balise n'importe où
  (En théorie du moins...)
- Interprétation **arborescente**

```
<table>
  <tr>
    <th>A1</th>
    <th>B1</th>
  </tr>
  <tr>
    <td>A2</td>
    <td>B2</td>
  </tr>
</table>
```

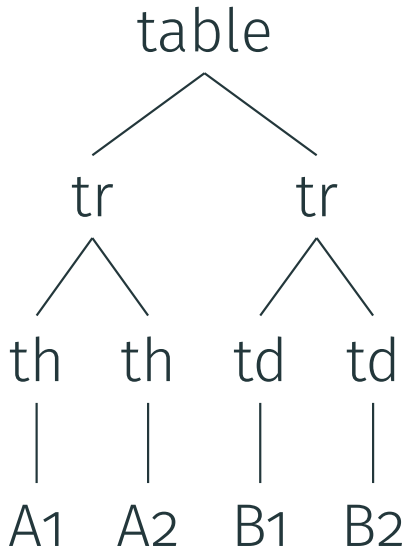

Structure générale

- Le `DOCTYPE` précise la **version** de HTML utilisée
  - → Cet exemple est en HTML5
- L'attribut `lang` (optionnel) précise la **langue**

```
<!DOCTYPE html>
<html lang="fr">
  <head>
    <!-- en-tête -->
  </head>
  <body>
    <!-- corps -->
  </body>
</html>
```

Structure générale

- Le `DOCTYPE` précise la **version** de HTML utilisée
  → Cet exemple est en HTML5
- L'attribut `lang` (optionnel) précise la **langue**

```
<!DOCTYPE html>
<html lang="fr">
  <head>
    <!-- en-tête -->
  </head>
  <body>
    <!-- corps -->
  </body>
</html>
```

(Démo : afficher le source de `https://www.lemonde.fr/`.)

En-tête

- L'en-tête contient les **méta-données** :

```
<head>
  <meta charset="utf-8">
  <title>Titre de la page</title>
  <meta name="description" content="blah">
  <!-- ... -->
</head>
```

- Indiquer l'**encodage**
- Indiquer le **titre**
- Autres indications pour les moteurs de recherche, le cache…
- `<script>` : voir plus tard

Soupe de balises

- Les gens écrivent souvent du HTML **n'importe comment**
- Compatibilité avec **tous les sites** depuis les débuts du Web

→ Les navigateurs sont **très** tolérants

→ Émulation **non-standardisée** des défauts d'interprétations de certains anciens navigateurs ! (quirks mode)

Soupe de balises

- Les gens écrivent souvent du HTML **n'importe comment**
- Compatibilité avec **tous les sites** depuis les débuts du Web

→ Les navigateurs sont **très** tolérants

→ Émulation **non-standardisée** des défauts d'interprétations de certains anciens navigateurs ! (quirks mode)

(Démo : soupe de tags)

Soupe de balises

- Les gens écrivent souvent du HTML **n'importe comment**
- Compatibilité avec **tous les sites** depuis les débuts du Web

→ Les navigateurs sont **très** tolérants

→ Émulation **non-standardisée** des défauts d'interprétations de certains anciens navigateurs ! (quirks mode)

(Démo : soupe de tags)

(Démo : validateur W3C)

Table des matières

SONDAGE : balises

Quelle balise moderne va par défaut mettre le texte en gras ?

- **A**: `<b>`
- **B**: `<em>`
- **C**: `<strong>`
- **D**: `<bold>`

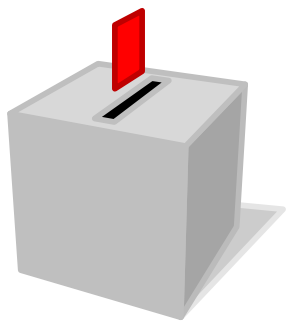

SONDAGE : balises

Quelle balise moderne va par défaut mettre le texte en gras ?

- **A**: `<b>`
- **B**: `<em>`
- **C**: `<strong>`
- **D**: `<bold>`

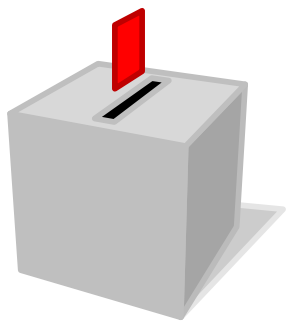

Texte

- Texte à mettre dans des **paragraphes** :
  - → Paragraphes délimités avec `<p> ... </p>`
  - → Pas de texte directement dans `<body>` !
- **Retour à la ligne** avec `<br>`
- Mettre **en valeur** dans un paragraphe :
  - → `<em> ... </em>`
  - → `<strong> ... </strong>`
  - → `<mark> ... </mark>`

Titres et structure

- Titres : de `<h1>` à `<h6>` (importance décroissante)
- Autres façons (purement sémantiques) de structurer la page :
  - `<header>` : en-tête
  - `<footer>` : pied-de-page
  - `<nav>` : élément de navigation
  - `<article>` : par exemple sur un blog
  - `<main>` : contenu principal de la page
  - `<dialog>` : boîte de dialogue

Listes

- A
- B
- C

```
<ul>
  <li>A</li>
  <li>B</li>
  <li>C</li>
</ul>
```

1. A
2. B
3. C

```
<ol>
  <li>A</li>
  <li>B</li>
  <li>C</li>
</ol>
```

X A

Y B

Z C

```
<dl>
  <dt>X</dt> <dd>A</dd>
  <dt>Y</dt> <dd>B</dd>
  <dt>Z</dt> <dd>C</dd>
</dl>
```

Tableaux

```
<table>
  <tr>
    <th>X1</th>
    <th>X2</th>
  </tr>
  <tr>
    <td>A1</td>
    <td>A2</td>
  </tr>
  <tr>
    <td>B1</td>
    <td>B2</td>
  </tr>
</table>
```

X1	X2
A1	A2
B1	B2

Tableaux complexes

`<caption>` Donner une **légende** au tableau

`<thead>` Délimiter l'**en-tête** du tableau (en-têtes de colonnes)

`<tfoot>` Délimiter le **pied de page** du tableau (somme…)

`<tbody>` Délimiter le **corps** du tableau

`<col>` Délimiter les **colonnes** :

```
<table>
  <colgroup>
    <col id="cle">
    <col span="2" id="valeurs">
  </colgroup>
  <tr>
    <td>K1</td>
    <td>Va1</td>
    <td>Vb1</td>
  </tr>
  <!-- ... -->
</table>
```

SONDAGE : liens

Quelle est la bonne façon de faire un lien vers le site de Télécom Paris ?

- **A**: `<a href="www.telecom-paris.fr">texte</a>`
- **B**: `<a href="http://www.telecom-paris.fr">texte</a>`
- **C**: `<a href="https://www.telecom-paris.fr">texte</a>`
- **D**: `<a href=https://www.telecom-paris.fr>texte</a>`

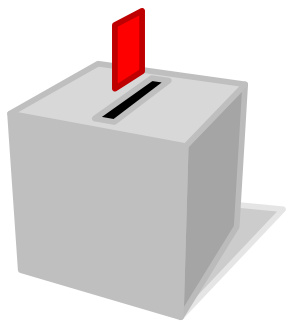

SONDAGE : liens

Quelle est la bonne façon de faire un lien vers le site de Télécom Paris ?

- **A**: `<a href="www.telecom-paris.fr">texte</a>`
- **B**: `<a href="http://www.telecom-paris.fr">texte</a>`
- **C**: `<a href="https://www.telecom-paris.fr">texte</a>`
- **D**: `<a href=https://www.telecom-paris.fr>texte</a>`

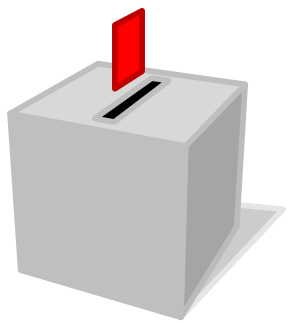

Liens

Liens hypertexte, d'où HTTP, HTML !

```
<a href="https://www.telecom-paris.fr/">Telecom</a>
```

Peut contenir un URL absolu (comme avant), mais aussi relatif

Considérons la page `https://example.com/foo/bar.html`

Lien	Résolution
`/quux`	`https://example.com/quux`
`..`	`https://example.com/`
`bar2.html`	`https://example.com/foo/bar2.html`
`baz/toto.html`	`https://example.com/foo/baz/toto.html`
`#top`	`https://example.com/foo/bar.html#top`

L'effet du fragment `#top` est de faire défiler jusqu'à l'élément portant l'attribut `id="top"`.

SONDAGE : requête

Sur une requête à `https://example.com/foo#bar`, quelle partie de la requête correspond au chemin dans la requête HTTP ?

- **A**: `www.telecom-paris.fr/foo#bar`
- **B**: `www.telecom-paris.fr/foo/`
- **C**: `/foo/#bar`
- **D**: `/foo/`

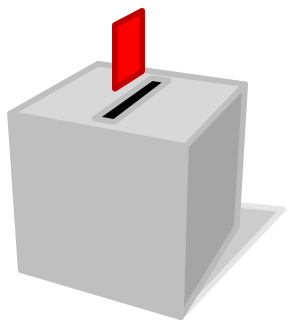

SONDAGE : requête

Sur une requête à `https://example.com/foo#bar`, quelle partie de la requête correspond au chemin dans la requête HTTP ?

- **A**: `www.telecom-paris.fr/foo#bar`
- **B**: `www.telecom-paris.fr/foo/`
- **C**: `/foo/#bar`
- **D**: `/foo/`

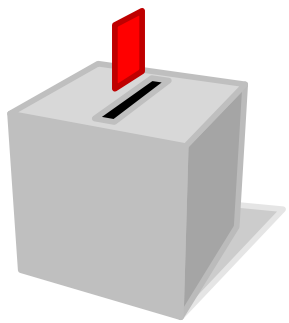

iFrames

- Afficher une autre page dans la page courante :

```
<iframe src="https://en.wikipedia.org/">
  <p>Pas de support iFrame !</p>
</iframe>
```

- Parfois pratique, mais **déconseillé** :
  - → Peut être **perturbant** pour l'utilisateur
  - → Pas toujours très **flexible**
  - → Complexe pour la **sécurité**

→ Préférer des solutions **côté serveur** (ou avec JavaScript)

→ Utilisé surtout pour les **intégrations de code tiers**

Table des matières

Images

- Depuis la **première spécification** de HTML (1993) :

  ```
  <img src="logo_telecom.png" alt="Logo Telecom">
  ```

- `src` précise l'**URL** où chercher l'image (absolu ou relatif)
- `alt` indique un texte **obligatoire** pour remplacer l'image :
  - → image non trouvée
  - → malvoyants
  - → navigateurs texte, ou mobile avec images désactivées
  - → robots

Note : l'image peut se trouver sur un **tout autre serveur** !

- → Requêtes **multiples**
- → **Inline linking** et risques

Aussi : `<figure>` et `<figcaption>` pour légender, `<picture>` et `<source>` pour spécifier plusieurs formats alternatifs (taille / format)

SONDAGE : Formats d'image (1/3)

Quel format d'image utiliser pour mettre une photo sur une page Web ?

- **A**: PNG
- **B**: JPEG
- **C**: WebP
- **D**: SVG

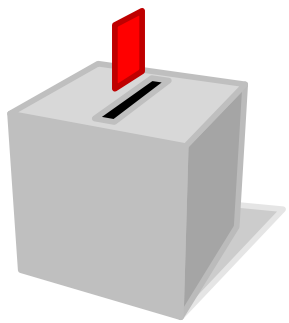

SONDAGE : Formats d'image (1/3)

Quel format d'image utiliser pour mettre une photo sur une page Web ?

- **A**: PNG
- **B**: **JPEG**
- **C**: WebP
- **D**: SVG

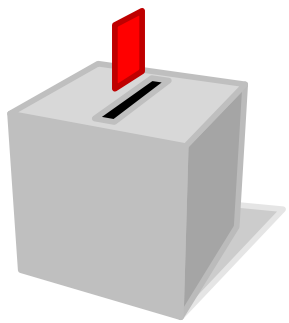

SONDAGE : Formats d'image (2/3)

Quel format d'image utiliser pour mettre une icône sur une page Web ?

- **A**: PNG
- **B**: JPEG
- **C**: WebP
- **D**: SVG

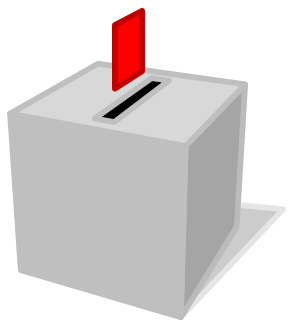

SONDAGE : Formats d'image (2/3)

Quel format d'image utiliser pour mettre une icône sur une page Web ?

- **A**: **PNG**
- **B**: JPEG
- **C**: WebP
- **D**: SVG

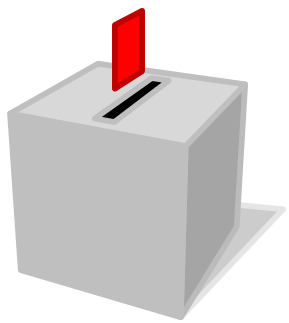

SONDAGE : Formats d'image (3/3)

Quel format d'image utiliser pour mettre un diagramme sur une page Web ?

- **A**: PNG
- **B**: JPEG
- **C**: WebP
- **D**: SVG

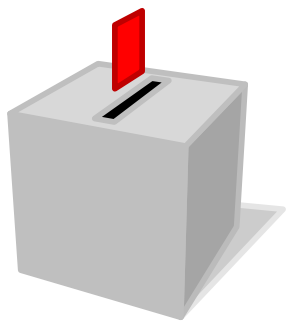

SONDAGE : Formats d'image (3/3)

Quel format d'image utiliser pour mettre un diagramme sur une page Web ?

- **A**: PNG
- **B**: JPEG
- **C**: WebP
- **D**: **SVG**

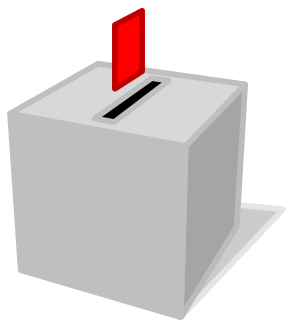

Formats d'image principaux

BMP Aucune compression, historique, à éviter

JPEG Compression appropiée aux photos

WebP Alternative plus récente (2010) par Google

PNG Compression sans perte adaptée aux dessins

GIF PNG en moins bien, mais supporte les animations

APNG PNG avec animation, alternative à GIF ; rare

SVG Images vectorielles : rendu calculé à partir de formes géométriques, zoomables sans pixelisation

Audio et vidéo

- Nouveau en HTML5 :

```
<audio src="audio.ogg">
  <p>Pas de support audio :
  <a href="audio.ogg">fichier audio.ogg</a>.</p>
</audio>
```

`controls` Afficher des contrôles de lecture (pas par défaut !)

`autoplay` Lecture automatique (à éviter…)

`loop` Lecture en boucle

`preload` Choisir le préchargement du fichier

`<source>` Plusieurs formats alternatifs

Élément `<video>` analogue pour la vidéo

Formats audio

Compliqué ! Codecs versus conteneurs

WAV Sans compression, à éviter

MID Rendu logiciel d'une partition : ne pas confondre

MP3 Format historique, peu efficace

AAC Successeur de MP3

FLAC Compression audio sans perte

Speex Compression audio optimisée pour la voix

Ogg Vorbis Alternative libre à MP3

Opus Alternative récente (2012 ; un codec pour les gouverner tous)

Formats vidéo

H.264 Format le plus répandu, mais problèmes de brevets

Ogg Theora Alternative libre, mais peu utilisée

WebM Format proposé par Google, libre. VP8 et VP9

- Le standard HTML5 ne privilégie plus Theora
- IE et Safari supportent uniquement H.264
- Firefox, Chrome, Android supportent tout
- Encrypted Media Extensions (HTML EME)
- Attention à la bande passante quand on héberge des vidéos :
  - Les héberger sur une plateforme comme Youtube
  - Utiliser Bittorrent en JavaScript, e.g., Peertube, WebTorrent

Table des matières

Bases

- Structure générale d'un formulaire :

```
<form action="action.php" method="get">
  <!-- contenu du formulaire ici -->
  <input type="submit">
</form>
```

`<input>` Bouton pour **valider** le formulaire (ici)

`action` URL vers lequel **soumettre**

`method` Quelle **méthode** utiliser pour la soumission

`enctype` Comment **encoder** les données du formulaire

→ Le navigateur effectuera la requête demandée en fournissant les données des champs du formulaire

→ Traitement effectué par le **serveur**

Retour à HTTP

- GET : les paramètres sont transmis dans le chemin :

```
GET action.php?lastname=Dupond&firstname=Jean HTTP/1.1
Host: example.com
```

- POST et `application/x-www-form-urlencoded` (par défaut) : c'est pareil, mais les données sont dans le corps :

```
POST action.php HTTP/1.1
Host: example.com
Content-Type: application/x-www-form-urlencoded

lastname=Dupond&firstname=Jean
```

Retour à HTTP (suite)

- POST et `multipart/form-data` : moins concis mais plus efficace pour de gros volumes :

```
POST action.php HTTP/1.1
Host: example.com
Content-Type: multipart/form-data; boundary=--e06

----e06
Content-Disposition: form-data; name="lastname"

Dupond
----e06
Content-Disposition: form-data; name="firstname"

Jean
----e06--
```

Champs texte

- Champ de base : le **champ texte** :

```
<form action="action.php" method="get">
  <label for="nom">Nom</label>
  <input name="lastname" id="nom" type="text"><br>
  <label for="prenom">Prénom</label>
  <input name="firstname" id="prenom" type="text">
  <input type="submit">
</form>
```

- L'élément `<label>` **explique** le champ et y est lié par son `id`
- L'attribut `name` définit le **nom** dans la requête HTTP :

```
POST action.php HTTP/1.1
Host: example.com
Content-Type: application/x-www-form-urlencoded

lastname=Dupond&firstname=Jean
```

Attributs du champ texte

`autofocus`	Champ à **sélectionner** au chargement
`placeholder`	Texte **explicatif** affiché quand le champ est vide
`disabled`	Champ **non modifiable**. (Aussi `readonly`.)
`autocomplete`	Tenter d'autocompléter avec valeurs **passées**
`value`	Contenu **par défaut**
`required`	Impose que le champ soit **rempli**
`type`	Multiples valeurs :
	→ `password` (étoiles)
	→ `email`
	→ `range` (avec `min` et `max`), `tel`, `number`, `color`…
`pattern`	Valider avec une **expression régulière** :
	→ `pattern="[0-9]{5}"` pour un code postal)

→ Validation plus complexe ou compatibilité : **JavaScript**

SONDAGE : Validation des entrées

Quelle technique garantit que l'utilisateur ne changera pas la valeur d'un champ en soumettant un formulaire ?

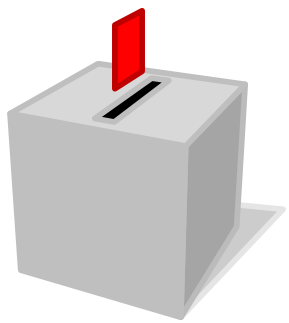

- **A**: L'attribut `diasbled`
- **B**: L'attribut `pattern`
- **C**: Une validation Javascript
- **D**: Autre technique

SONDAGE : Validation des entrées

Quelle technique garantit que l'utilisateur ne changera pas la valeur d'un champ en soumettant un formulaire ?

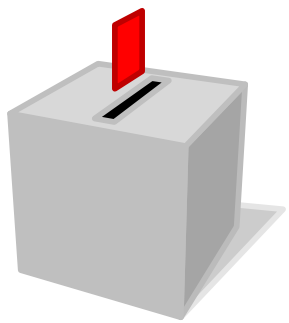

- **A**: L'attribut `diasbled`
- **B**: L'attribut `pattern`
- **C**: Une validation Javascript
- **D**: **Autre technique**

Boutons radio

- Sélectionner parmi **plusieurs choix** :

```
<input type="radio" name="choix" id="oui" value="oui">
<label for="oui">Oui</label><br>
<input type="radio" name="choix" id="pe" value="pe">
<label for="pe">Peut-être</label><br>
<input type="radio" name="choix" id="non" value="non">
<label for="non">Non</label><br>
```

- Partagent le même `name` mais ont des `value` **différentes**
- **Non exclusifs** si `name` différents

Cases à cocher

- Sélectionner des choix **non exclusifs** :

```
<input type="checkbox" name="lu" id="lu">
<label for="lu">Lu</label><br>
<input type="checkbox" name="approuve" id="approuve">
<label for="approuve">Approuvé</label>
```

- Autre possibilité :

```
<input type="checkbox" name="c[]" value="lu" id="lu">
<label for="lu">Lu</label><br>
<input type="checkbox" name="c[]" value="ap" id="ap">
<label for="ap">Approuvé</label>
```

- Attribut `checked` : coché **par défaut**
- Le `[]` est pour indiquer que le nom contient **plusieurs valeurs**, nécessaire pour certains langages serveur (PHP...)

Listes déroulantes

- Sélectionner parmi une liste de choix :

```
<label for="affiliation">Affiliation</label>
<select name="affiliation" id="affiliation">
  <option value="ecp">École centrale de Paris</option>
  <option value="x">École polytechnique</option>
  <option value="ese">ESE</option>
  <option value="instn">INSTN</option>
  <option value="telecom">Télécom Paris</option>
  <option value="sud">Université Paris-Sud</option>
</select>
```

`selected` Sélectionné par défaut

`multiple` Sélectionner plusieurs éléments (utiliser `[]`)

`<optgroup>` Former des groupes d'options

Upload de fichiers

- Joindre un **fichier** au formulaire :

```
<label for="fichier">Fichier à soumettre</label>
<input type="file" name="fichier" id="fichier">
```

- **Impérativement** utiliser `post` et `multipart/form-data` !
- Spécifier le **type de fichier** attendu (MIME) avec `accept`
- `multiple` pour **plusieurs fichiers**
- **Pas de garanties !** À revalider
- **Taille maximale** à imposer côté serveur

Boutons

`<input type="submit">` Valide le formulaire

`<input type="image" src="submit.png" alt="Submit">` Valide le formulaire (image)

`<input type="reset">` Réinitialise le formulaire

`<button>` Ne fait rien (JavaScript)

`value="texte"` Précise le texte du bouton

Autres

`<fieldset>` Regrouper des champs par groupes, annotés avec `<legend>`

`<datalist>` Spécifier des autocomplétions possibles

`type="hidden"` Champs cachés :

- → Forcer l'**ajout** d'un champ à la requête
- → Pourquoi faire ? Voir **plus tard**
- → À **revalider** côté serveur !

`<textarea>` Champ texte multilignes :

```
<textarea name="adresse" id="adresse" rows="3" cols="42">
  (Valeur par défaut.)
</textarea>
```

Langages de balisage légers

Langages pour ne pas écrire directement du HTML, e.g., Markdown

```
# Mon titre

Voici un *document*
avec du `monospace`
et voici une liste :

* Un
* Deux

et voici un lien :
[A](https://a3nm.net/)
```

```
<h1>Mon titre</h1>

<p>Voici un <em>document</em>
avec du <code>monospace</code>
et voici une liste :</p>

<ul>
<li>Un</li>
<li>Deux</li>
</ul>

<p>et voici un lien : <a
href="https://a3nm.net/">A</a>
</p>
```

Crédits

- Matériel de cours inspiré de notes par Pierre Senellart
- Merci à Marc Jeanmougin, Antonin Delpeuch et Pierre Senellart pour leur relecture